第10讲-大数据-RAG 检索增强生成-课后小组作业

一、作业目标

完整复盘 RAG 整套技术栈：原理、离线-在线架构、Embedding、向量数据库、Chunk 切分、Rerank 重排序、多模态表格 RAG、企业级向量库 Milvus。
本课程下周四（2026.10.22）课堂安排：进行分组作业的小组汇报，具体要求见下面。
小组分工协作，既要有理论梳理，又要有可运行代码 Demo 演示，做到理论 + 实战结合。
锻炼口头汇报、现场演示、应答提问的工程汇报能力。

二、小组分工参考（每组 3-5 人，汇报时每个人都要有发言内容）

大家可以根据情况进行自由组合分组，具体就在本表格的另外一个sheet里面填写。
以下为分工的一个示例，可以根据自己情况进行组内调整。

角色	人数	核心职责	汇报环节任务
总述负责人	1 人	梳理 RAG 整体背景、大模型痛点、RAG vs 微调对比，梳理整体系统架构	汇报开场：1 分钟，介绍项目背景、RAG 核心价值、小组分工，介绍本组完成工作
技术原理讲解人	1-2 人	负责拆解关键模块：文本切分策略、Embedding 与相似度计算、Rerank 重排序、多模态 RAG 表格处理原理 / Milvus 企业向量库原理	2-2.5 分钟：分模块讲解核心原理、课堂思考题理解、踩坑点分析；每人负责 1-2 个技术模块
程序演示工程师	1 人	负责代码调试，准备运行环境：笔记本本地运行 / 远程服务器运行；备选方案：录屏录像（仅现场无法运行时使用）	1-1.5 分钟：现场运行 Demo，展示关键现象，例如：不同 chunk 大小效果对比、Rerank 前后排序变化、表格多模态检索效果；Milvus 检索演示；演示结束快速切回 jupyter notebook或者PPT
应答 & 总结人	1 人	梳理作业难点、收获、遗留问题；提前预判老师可能提问；负责汇报收尾；接收老师提问并组织组员共同作答	汇报结尾 30 秒总结；老师提问环节主要应答人，可以协同组员补充回答

说明：小组人数较少时可以合并部分角色，但**每位组员必须有口头输出，不允许有人只做幕后不发言。**
尽量不要单人为一个分组，可以尽量联系其他同学一起完成。

三、作业任务内容（小组共同完成）

任务 1：理论梳理（jupyter notebook或者PPT 汇报材料）

结合课堂讲义，jupyter notebook或者PPT 内容至少覆盖如下要点：

大模型固有三大局限；RAG 与微调的优缺点对比。

RAG 两阶段架构：**离线阶段、在线阶段**完整流程，画出系统流程图。
关键技术点选讲（小组可以侧重 2-3 个重点）：

文本切分 Chunk 策略：chunk_size、overlap 重叠的意义；过大 / 过小带来的问题。
Embedding 向量、余弦相似度与欧氏距离差异；为什么 RAG 优先选余弦相似度。
Rerank 两阶段检索（粗召回 + 精排）原理，Bi-Encoder 与 Cross-Encoder 区别。
多模态 RAG 处理 PDF 表格的整套流程，分析该方案存在的局限性。
Chroma 与 Milvus 选型对比；Milvus 核心概念（Collection、索引 IVF-FLAT/HNSW，nlist/nprobe 参数含义）。

结合讲义中的课堂思考题，写出小组理解，把思考题融入 jupyter notebook或者PPT。
总结本组实践遇到的问题、踩坑、解决方案。

任务 2：代码实践（必须准备可演示 Demo）

允许基于讲义提供的源码修改，不要求从零手写全部代码，但必须理解每段代码逻辑。 小组从下面 3 个选题**三选一**完成代码实验：

选题 A【基础 RAG 系统】：实现基础 RAG Bot，做对照实验 1）简单段落切分 vs 带 overlap 重叠切分，对比两种切分策略下问答效果差异； 2）观察 temperature=0 和 temperature=1.0 输出结果的差异； 3）现场展示检索结果与 RAG 回答。

选题 B【进阶 RAG：Rerank 重排序】 1）向量检索粗召回 Top5，再使用 Cross-Encoder 做 Rerank 精排； 2）对比 Rerank 前后文档排序变化，展示 “向量检索排第 4 的文档，经过 rerank 提升到第 1” 的现象； 3）分析重排序对最终问答答案的影响。

选题 C【多模态 / 企业向量库二选一】

C-1 多模态表格 RAG：复现 PDF 表格检测→截图→VLM 生成文本描述→向量入库，实现对表格内容检索提问；
C-2 Milvus 企业向量库：把原本 Chroma 实现的 RAG 知识库迁移到 Milvus，演示 Milvus 检索，调试 nlist/nprobe 参数，观察召回结果变化。

演示环境要求

优先：**组员携带笔记本电脑，现场运行 Jupyter 代码；或提前配置远程服务器，现场通过远程桌面 / 网页访问运行。**
注意：讲台电脑是普通win10 PC，没有Pytorch, transformers等环境。但是，能够通过HDMI线外接电脑显示，也可以用讲台电脑开远程桌面ToDesk连接远程服务器。
务必制定兜底预案：如果现场环境运行失败，用提前录制程序运行录像，用U盘播放，但是不允许全程只放录像，优先现场实机运行。

四、汇报规则（下周四课堂路演）

每组严格**5 分钟以内**，计时结束立刻停止展示；分配建议：开场 1min + 原理讲解 2.5min + Demo 演示 1.5min + 简短收尾。
汇报结束后老师随机提问，小组全员可以参与作答，应答质量计入成绩。
jupyter notebook或者PPT 建议页数：8-12 页，不要大段复制讲义文字，多用流程图、截图、代码运行截图、对比实验结果。
分组登记：自行组队 3-5 人，把组号、组员姓名、分工、本组选题，填写到 QQ 群下发的在线 Excel 表格。

五、评分维度（作业成绩参考）

分工合理性：人人参与汇报，角色清晰（25%）
理论理解：RAG 原理、关键技术理解到位，思考题有自己小组分析（30%）
代码实践：Demo 可运行，有对照实验，能展示现象，不是单纯跑通样例（30%）
汇报表现：时间把控、表达逻辑，提问环节应答（15%）

六、注意

分组登记：QQ 群在线 Excel表格填写，即本表格的另外一个sheet里面填写。
课堂汇报下周四现场完成；